



**AKADEMIA GÓRNICZO-HUTNICZA IM. STANISŁAWA STASZICA W KRAKOWIE**

**WYDZIAŁ ELEKTROTECHNIKI, AUTOMATYKI,  
INFORMATYKI I INŻYNIERII BIOMEDYCZNEJ**

KATEDRA INFORMATYKI STOSOWANEJ

Praca dyplomowa inżynierska

*Automatyczne odkrywanie procesów biznesowych przy użyciu  
programowania genetycznego*

*Automated Business Process Discovery using Genetic Programming*

Autor:

*Piotr Seemann*

Kierunek studiów:

*Informatyka*

Opiekun pracy:

*dr inż. Krzysztof Kluza*

Kraków, 2021

*Uprzedzony o odpowiedzialności karnej na podstawie art. 115 ust. 1 i 2 ustawy z dnia 4 lutego 1994 r. o prawie autorskim i prawach pokrewnych (t.j. Dz.U. z 2006 r. Nr 90, poz. 631 z późn. zm.): „Kto przywłaszcza sobie autorstwo albo wprowadza w błąd co do autorstwa całości lub części cudzego utworu albo artystycznego wykonania, podlega grzywnie, karze ograniczenia wolności albo pozbawienia wolności do lat 3. Tej samej karze podlega, kto rozpowszechnia bez podania nazwiska lub pseudonimu twórcy cudzy utwór w wersji oryginalnej albo w postaci opracowania, artystycznego wykonania albo publicznie zniekształca taki utwór, artystyczne wykonanie, fonogram, wideogram lub nadanie.”, a także uprzedzony o odpowiedzialności dyscyplinarnej na podstawie art. 211 ust. 1 ustawy z dnia 27 lipca 2005 r. Prawo o szkolnictwie wyższym (t.j. Dz. U. z 2012 r. poz. 572, z późn. zm.): „Za naruszenie przepisów obowiązujących w uczelni oraz za czyny uchybiające godności studenta student ponosi odpowiedzialność dyscyplinarną przed komisją dyscyplinarną albo przed sądem koleżeńskim samorządu studenckiego, zwanym dalej «sądem koleżeńskim».”, oświadczam, że niniejszą pracę dyplomową wykonałem(-am) osobiście i samodzielnie i że nie korzystałem(-am) ze źródeł innych niż wymienione w pracy.*

*Serdecznie dziękuję ...*



## Spis treści

<b>1. Wprowadzenie</b>	7
1.1. Cele pracy	7
1.2. Przegląd prac	7
1.3. Zawartość pracy	7
<b>2. Wstęp teoretyczny</b>	9
2.1. Procesy biznesowe	9
2.1.1. Procesy Biznesowe	9
2.1.2. Dzienniki zdarzeń	9
2.2. Modelowanie procesów biznesowych	9
2.3. Algorytmy do wykrywania procesów biznesowych	9
2.4. Ewolucja genetyczna	9
2.4.1. Algorytmy genetyczne	9
2.4.2. Ewolucja genetyczna a inne algorytmy uczenia maszynowego	9
2.4.3. Ewolucja gramatyczna	9
2.5. Gramatyka	9
2.5.1. BNF	9
2.5.2. Tworzenie gramatyki pod kątem ewolucji	9
2.6. Metryki	9
2.6.1. Prostota	10
2.6.2. Odwzorowanie	10
2.6.3. Precyzja	10
2.6.4. Generalizacja	10
2.6.5. Złożoność	10
<b>3. Projekt i implementacja</b>	11
3.1. Wykorzystane technologie	11
3.1.1. Python 3.8.1	11
3.1.2. PonyGE2	11

3.2.	Tworzenie gramatyki procesu biznesowego .....	11
3.3.	Projekt systemu .....	14
3.4.	Implementacja .....	15
3.5.	Wybór parametrów algorytmu .....	20
<b>4.</b>	<b>Dyskusja rezultatów .....</b>	<b>25</b>
4.1.	Przykładowe wyniki .....	25
4.2.	Porównanie z innymi algorytmami .....	25
4.3.	Wyniki w zależności od przyjętych metryk .....	25
4.4.	Wnioski .....	25
<b>5.</b>	<b>Podsumowanie .....</b>	<b>27</b>

# **1. Wprowadzenie**

## **1.1. Cele pracy**

## **1.2. Przegląd prac**

## **1.3. Zawartość pracy**





## **2. Wstęp teoretyczny**

### **2.1. Procesy biznesowe**

#### **2.1.1. Procesy Biznesowe**

#### **2.1.2. Dzienniki zdarzeń**

### **2.2. Modelowanie procesów biznesowych**

### **2.3. Algorytmy do wykrywania procesów biznesowych**

#### **2.3.0.1. Alpha algorithm**

#### **2.3.0.2. The ILP Miner**

#### **2.3.0.3. Heuristic Miner**

#### **2.3.0.4. Multi-phase Miner**

### **2.4. Ewolucja genetyczna**

#### **2.4.1. Algorytmy genetyczne**

[1]

#### **2.4.2. Ewolucja genetyczna a inne algorytmy uczenia maszynowego**

#### **2.4.3. Ewolucja gramatyczna**

### **2.5. Gramatyka**

#### **2.5.1. BNF**

#### **2.5.2. Tworzenie gramatyki pod kątem ewolucji**

### **2.6. Metryki**

[2]

### 2.6.1. Prostota

$$M_{pro} = 1 - \frac{\text{ilosc duplikatow w modelu} + \text{ilosc brakujacych wartosci w modelu}}{\text{ilosc unikalnych zdarzen w logu} + \text{ilosc zdarzen w modelu}}$$

### 2.6.2. Odwzorowanie

$$M_o = 1 - \sum_{n=-\infty}^{+\infty} \frac{\text{blad odwzorowania logu w modelu}}{\text{dugosc sciezki w modelu}}$$

### 2.6.3. Precyzja

$$M_{pre} = 1 - \sum_{n=-\infty}^{+\infty} \sqrt{2}$$

### 2.6.4. Generalizacja

$$M_g = 1 - \sum_{n=-\infty}^{+\infty} \sqrt{2}$$

### 2.6.5. Złożoność

$$M_z = 1 - \sum_{n=-\infty}^{+\infty} \sqrt{2}$$

## 3. Projekt i implementacja


### 3.1. Wykorzystane technologie

#### 3.1.1. Python 3.8.1

Do implementacji algorytmu został użyty Python. Jest to najpopularniejszy język programowania w dziedzinie uczenia maszynowego. Wymagana jest wersja 3.8+ ze względu na użycie w implementacji metod dostępnych od tej wersji.

#### 3.1.2. PonyGE2

PonyGE2 [3] jest implementacją ewolucji genetycznej w języku Python. Pozwala na łatwą konfigurację parametrów ewolucji genetycznej oraz łatwą możliwość dodania własnych problemów oraz sposobów ewaluacji wyników.



Rys. 3.1. Pętla wyszukiwania

### 3.2. Tworzenie gramatyki procesu biznesowego

Przy tworzeniu gramatyki procesu biznesowego ważnym jest, żeby znaleźć balans, jeśli chodzi o poziom skomplikowania zaproponowanej gramatyki. W pracy [4] autorzy przeanalizowali składniki języka BPMN pod kątem częstotliwości ich stosowania. z pracy wynika, że najczęściej stosowanymi elementami

modelów procesu biznesowego, jeśli chodzi o bramki są: xor, and oraz pętlexe lop. Do przedstawionej poniżej gramatyki dodano także bramkę opt, czyli or jako uogólnienie bramki xor w celu uniknięcia zagnieżdżonych bramek xor. Ponadto koniecznym jest posiadanie bramki seq, która oznacza normalny przepływ procesów.

Zapis `GE_RANGE:n` jest rozszerzenie do gramatyki zapewnianym przez PonyGE2, które umożliwia dodanie ilości zmiennych, czyli `GE_RANGE:2` oznacza 0|1|2. Wzorując się na Zapis `GE_RANGE:dataset_vars` jest rozszerzenie do gramatyki zapewnianym przez PonyGE2, które umożliwia dodanie ilości zmiennych odpowiadającej ich ilości w zbiorze danych.

```
<e> ::= <anygate>

<andgate> ::= and(<anygate><anygate>) | and(<anygate>)

<xorgate> ::= xor(<anygate><anygate>) | xor(<anygate>)

<seqgate> ::= seq(<anygate><anygate>) | seq(<anygate>)

<optgate> ::= opt(<anygate><anygate>) | opt(<andgate>) | opt(<xorgate>) |
              opt(<seqgate>) | opt(<longate>) | opt({<event>})

<longate> ::= lo<0_n>(<anygate><anygate>) | lo<0_n>(<andgate>) |
              lo<0_n>(<xorgate>) | lo<0_n>(<optgate>) | lo<0_n>({<event>})

<anygate> ::= <anygate><anygate> | <andgate> | <xorgate> | <seqgate> | <optgate> |
              <longate> | {<event>}

<event> ::= GE_RANGE:dataset_vars

<0_n> ::= GE_RANGE:2
```

**Listing 3.1.** Gramatyka procesu biznesowego


Przykład wygenerowanej gramatyki: `and({d}opt({f})and({a}{c})lop(seq(lop({a}){e})))`

Wszystkie bramki mają nazwy tej samej długości - 3 znaki, co pozwoli na łatwiejsze parsowanie gramatyki.

`longate` - oznacza pętle Poniższy przykład pokazuje gramatykę, którą ciężko opisać przy pomocy podstawowych bramek logicznych:

Jest to możliwe za pomocą notacji: `{a}and(xor({b}{c}){d}){e}lop({f}and(xor({b}{c}){d}){e})xor({g}{h})`

Użycie powyższej notacji rodzi jednak kilka problemów, Musimy mieć produkcje `{a}lo1({f}and(xor({b}{c}){d}){e})xor({g}{h})`


**Rys. 3.2.** Przykład problemu

### 3.3. Projekt systemu

#### 3.3.0.1. Podział na moduły

Implementację podzielone na następujące moduły:

- wrappers - PonyGE2 nie jest przystosowane do zaimportowania jako biblioteka, dlatego żeby oddzielić kod PonyGE2 od naszego kodu należało rozszerzyć lub nadpisać część z modułów PonyGE2. Moduły, które nadpisano to params, który zawiera konfigurację aplikacji oraz grammar, gdzie dodano zmiany w jaki sposób parsowana jest podana gramatyka.
- fitness\_functions - zawiera klasę bazowy moduł, gdzie znajduje się bazowa klasa dla obliczania metryk
- process\_discovery - moduł zawiera całą logikę obliczenia metryk



Rys. 3.3. Podział na moduły

### **3.3.0.2. Model**

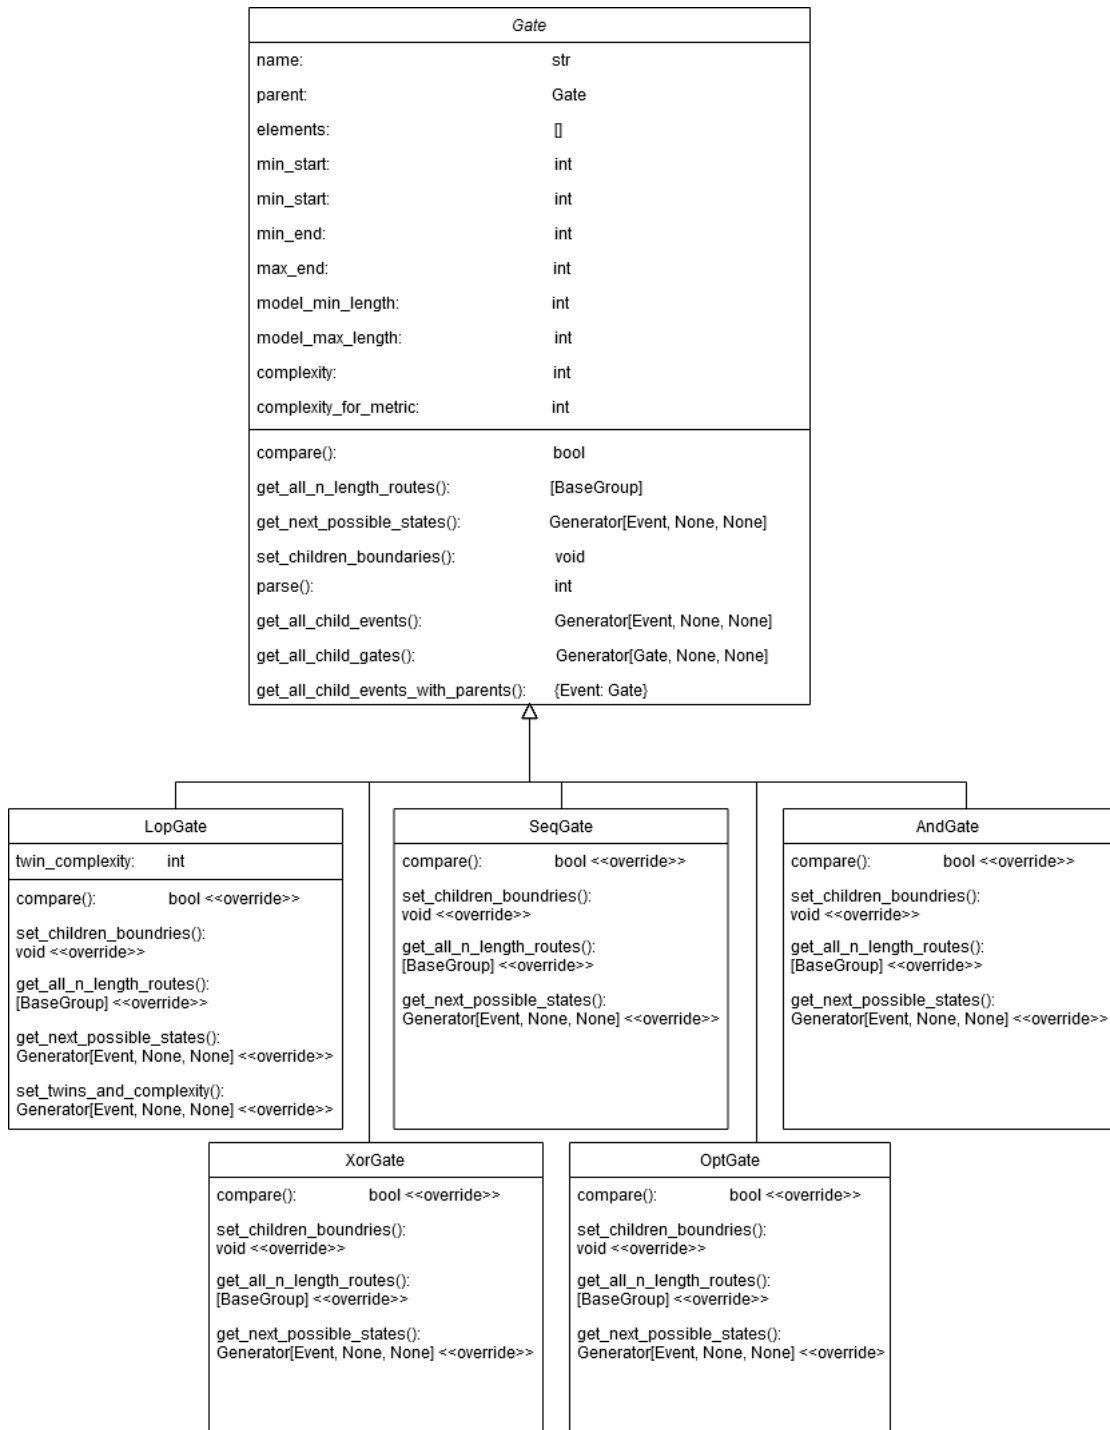
Podział na dwie klasy przydatne na różnym etapie procesowania:

Gate:

Event group:


## **3.4. Implementacja**

### **3.4.0.1. Ogólny schemat blokowy**

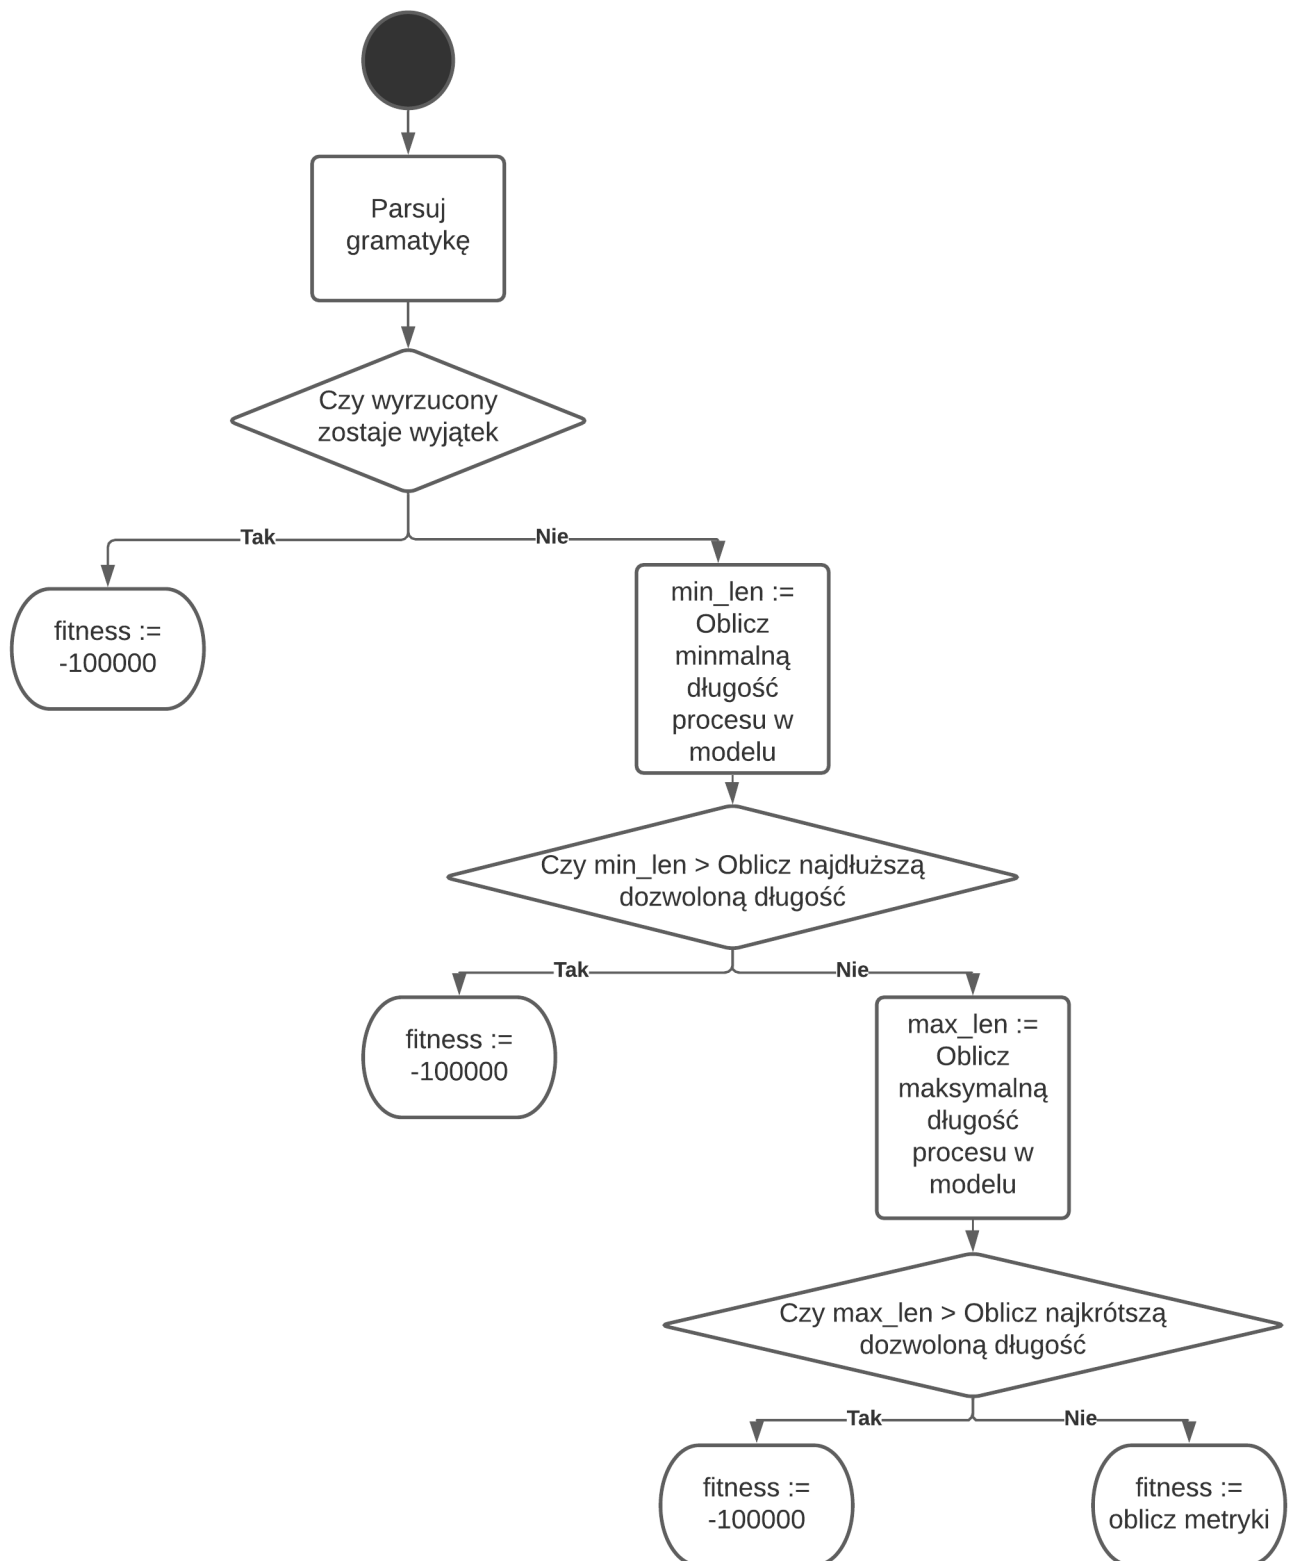


Rys. 3.4. Gate UML





Rys. 3.5. Event UML



Rys. 3.6. Ogólny schemat blokowy

### 3.4.0.2. Parsowanie gramatyki

Parser pozwala na przetworzenie wyników uzyskanych na drodze ewolucji gramatycznej na postać, na której łatwiej będzie operować. Rezultaty uzyskane na drodze rewolucji gramatycznej w PonyGE2 są w formie tekstowej, z którą praca byłaby niewygodna, dlatego używamy parsera, żeby otrzymać wynik w postaci drzewa obiektów Gate, którego liśćmi będą obiekty Event. Parsując korzystamy z faktu, że przy projektowaniu gramatyki wszystkie bramki logiczne zostały oznaczone 3 literowymi symbolami, a wszystkie zdarzenia otoczone nawiasami klamrowymi. Tworząc każdy obiekt Event dodajemy informację o liczbie dzieci tego obiektu, co przyda nam się przy obliczaniu metryki precyzja.

```
def parsuj(wyrażenie: str) -> int:

    for i w zakresie długość_wyrażenia:
        if wyrażenia[i] == "{":
            zdarzenie := Event(wyrażenia[i + 1])
            dodaj zdarzenie do aktualnie parsowanej bramki
            i += 2
        elif wyrażenia[i] == ")":
            return i+1
        elif i+4 < długość_wyrażenia:
            bramka := stwórz nową bramkę Gate typu zgodnego z wyrażeniem
            i += 3
            przeparsowane_znaki = bramka.parsuj(wyrażenie[i+4:])
            dodaj zdarzenie do aktualnie parsowanej bramki
            i += ilość_przeparsowanych_znaków
        else:
            wyrzuc wyjątek
```

**Listing 3.2.** Parser gramatyki

### 3.4.0.3. Obliczanie metryk

W pierwszej kolejności obliczamy metrykę dla dopasowania. Wszystkie inne metryki są obliczane dla najlepiej dopasowanej gramatyki

### 3.4.0.4. Obliczanie metryk dla jednego procesu

### 3.4.0.5. Wyszukiwanie w modelu procesów o określonej długości

Algorytm rekurencyjny. Implementacja różni się w zależności od przeszukiwanej bramki logicznej.

### 3.4.0.6. Obliczanie dopasowania

Pomysł zaczerpnięty z algorytmu Needlessmann-Wunsch [5], który jest uogólnieniem odległości Levenshteina. Rozwinięty o możliwość przeszukiwania modelu rekurencyjnie oraz o możliwość podawania listy równogłębłych zdarzeń.

```
perfectly_aligned_logs = dict()
cumulated_error = 0

for elem in log_info.log.keys():
    best_local_error, events_global, best_event_group = \
        calculate_metrics_for_single_process(elem, gate, min_length, max_length, alignment_cache)

    if any(event is not None and event not in model_events_list for event in events_global):
        value, events_global = get_best_alignment(best_event_group, list(elem), dict())
        best_local_error = calculate_alignment_metric(value, len(elem), len(best_event_group))
    if best_local_error == 0:
        perfectly_aligned_logs[tuple(events_global)] = log_info.log[elem]
    add_executions(model_events_list, events_global, log_info.log[elem])
    cumulated_error += best_local_error * log_info.log[elem]

return best_result
```

**Listing 3.3.** Obliczanie metryk

#### 3.4.0.7. Znajdowanie ścieżki w modelu

Potrzebne do obliczenia precyzji oraz generalizacji.

#### 3.4.0.8. Cache

Wiele obliczeń się powtarza, dlatego żeby przyspieszyć działanie rezultaty są cachowane w dwóch miejscach: Cache genotypów, dostarczane przez Cache obliczeń dopasowanie, które jest najbardziej kosztownym obliczeniem. Wybrane metodę cachowania LRU.

### 3.5. Wybór parametrów algorytmu

```
def oblicz_metryki(log_info, model, najkrótsza_dozwolona_długość,
                  najdłuższa_dozwolona_długość, cache) -> int:

    stosunek_wspólnych_zdarzeń_w_logu_i_modelu := oblicz_stosunek_wspólnych_zdarzeń_w_logu_i_modelu
    if stosunek_wspólnych_zdarzeń_w_logu_i_modelu < MINIMALNY_STOSUNEK_WSPÓLNYCH_ZDARZEŃ_W_LOGU_I_MODELU:
        return stosunek_wspólnych_zdarzeń_w_logu_i_modelu/10

    idealnie_dopasowane_logi := słownik()
    skumulowany_błąd := 0

    for proces w log:
        błąd_lokalny, ścieżka = oblicz_dopasowanie(event_group, elem)
        if błąd_lokalny < minimalny_błąd_lokalny:
            minimalny_błąd_lokalny = błąd_lokalny
            najlepsza_ścieżka = ścieżka
            najlepszy_błąd_lokalny += minimalny_błąd_lokalny
        oblicz_metryki(odwzorowanie, precyzja, generalizacja, prostota)
        najlepszy_wynik_lokalny = suma_obliczonych_metryk / liczba_metryk
        if najlepszy_wynik_lokalny > najlepszy_wynik:
            najlepszy_wynik = najlepszy_wynik_lokalny
    metryki := oblicz_metryki
    najlepszy_wynik := średnia ważona metryk
    return najlepszy_wynik
```

**Listing 3.4.** Obliczanie metryk

```

def oblicz_metryki_dla_jednego_procesu(process, model, najkrótsza_dozwolona_długość,
                                       najdłuższa_dozwolona_długość, cache):

    len_process = len(process)
    n = len_process
    i = 1
    min_local = -2 * n
    events_global = []
    best_event_group = []
    find = False

    while not n <= oblicz_minimalna_dozwolona_długość(len_process, min_error_local) and \
           not n >= oblicz_maksymalna_dozwolona_długość(len_process, min_error_local):
        best_local_alignment = -1
        if min_length <= n <= max_length:
            set_model_children_boundaries(model, n)
            routes = model.get_all_n_length_routes(n, process)

            if routes is not None and not is_struct_empty(routes):
                routes = set(routes)
                route_and_process_events_ratios = []
                for event_group in routes:
                    ratio = check_route_with_log_process(event_group, process)
                    if ratio >= 1 - 6 * params['RESULT_TOLERANCE_PERCENT']/100:
                        route_and_process_events_ratios.append((event_group, ratio))
                sorted_routes_and_ratios = sorted(route_and_process_events_ratios, key=lambda x: -x[1])
                for event_group_and_ratios in sorted_routes_and_ratios:
                    if event_group_and_ratios[1] <= 1 + min_local/len_process:
                        break
                value, events = get_best_alignment_cached(event_group_and_ratios[0], list(process))
                if value > min_local:
                    min_local = value
                    events_global = events
                    best_event_group = event_group_and_ratios[0]
                if value == 0:
                    find = True
                    break

                local_alignment = calculate_alignment_metric(min_local, len_process, n)
                if local_alignment > best_local_alignment:
                    best_local_alignment = local_alignment
                if find:
                    break

            n += (-1 if i % 2 == 1 else 1)
            i += 1

    return best_local_alignment, events_global, best_event_group

```

---

P. Seemann    *Automatyczne odkrywanie procesów biznesowych przy użyciu programowania genetycznego*

```

    ilość_wspólnych_zdarzeń_w_logu_i_modelu =
    if model_to_log_events_ratio < 1 - params['RESULT_TOLERANCE_PERCENT']/100:
        return model_to_log_events_ratio/10
    for elem w log:

```

**Listing 3.6.** Wyszukiwanie procesów o długości n

```
def oblicz_dopasowanie(model, log):
    kara = {'DOPASOWANIE': 0, 'BRAK_DOPASOWANIA': -2, 'PRZERWA': -1}
    wyniki_lokalne = [None] * dlugosc_macierzy_rozwiazan
    macierz_rozwiazan = Zainicjalizuj macierz zerami
    for i in range(m):
        macierz_rozwiazan[i][0] = kara['PRZERWA'] * i
    for j in range(n):
        macierz_rozwiazan[0][j] = kara['PRZERWA'] * j
    # Wypełnij osie macierzy właściwymi wartościami

    for i in range(1, m):
        if should_go_recurrent(model[i-1]):
            al_mat[i], model_results_local[i] =
                recurrent_alignment(al_mat[i - 1], model[i - 1],
                                   [x for x in substrings_of_string_reversed(log)], i)
        elif len(model[i-1]) > 1:
            al_mat[i], model_results_local[i] =
                parallel_alignment(al_mat[i - 1], model[i - 1],
                                  [x for x in substrings_of_string_reversed(log)], kara, i)
        else:
            al_mat[i][0] = al_mat[i-1][0] + penalty['PRZERWA']
            basic_alignment(al_mat, model[i - 1], log, kara, i, n)

    model_results = get_all_tracebacks(al_mat, penalty['PRZERWA'], model,
                                       log, model_results_local)

    return macierz_rozwiazan[m-1] #ostatnia linijka, model_results
```

**Listing 3.7.** Obliczanie dopasowania

```

def znajdz_sciezke(macierz_rozwiazan, model, log, rozwiazania_podmodeli):
    sciezka = []

    while i != 0:
        event_group_full_length = len(model[i - 1])
        if model_results_local[i] is not None:
            matched_flag = False
            if array[i][j] == array[i - 1][j] + event_group_full_length * penalty_gap:
                [model_result.append(None) for _ in range(event_group_full_length)]
                array[i][j] = 0
                i -= 1

            else:
                for k in range(j):
                    processes = get_not_none(model_results_local[i][k]
                        [len(model_results_local[i][k]) - (j-k)], log)
                    if array[i][j] == array[i - 1][k] +
                        (event_group_full_length + (j-k) - 2 * len(processes)) * penalty_gap:
                        [model_result.append(x) for x in processes]
                        for x in processes:
                            log = log.replace(x.name, "", 1)
                        [model_result.append(None)
                            for _ in range(event_group_full_length - len(processes))]
                        array[i][j] = 0
                        i -= 1
                        j = k
                        matched_flag = True
                        break

                if not matched_flag:
                    if array[i][j] == array[i][j - 1] + penalty_gap:
                        array[i][j] = 0
                        j -= 1

            else:
                if array[i][j] == array[i - 1][j] + penalty_gap:
                    model_result.append(None)
                    array[i][j] = 0
                    i -= 1
                elif array[i][j] == array[i][j - 1] + penalty_gap:
                    array[i][j] = 0
                    j -= 1
                elif array[i][j] == array[i - 1][j - 1]:
                    model_result.append(model[i-1])
                    log = log.replace(model[i-1].name, "", 1)
                    array[i][j] = 0
                    i -= 1
                    j -= 1

    return sciezka

```



## **4. Dyskusja rezultatów**

### **4.1. Przykładowe wyniki**

### **4.2. Porównanie z innymi algorytmami**

### **4.3. Wyniki w zależności od przyjętych metryk**

### **4.4. Wnioski**



## **5. Podsumowanie**



## Bibliografia

- [1] John R. Koza. *Genetic Programming: On the Programming of Computers by Means of Natural Selection*. Cambridge, MA, USA: MIT Press, 1992. ISBN: 0262111705.
- [2] J. C. A. M. Buijs, B. F. van Dongen i W. M. P. van der Aalst. „Quality Dimensions in Process Discovery: The Importance of Fitness, Precision, Generalization and Simplicity”. W: *International Journal of Cooperative Information Systems* 23.01 (2014), s. 1440001. DOI: 10.1142/S0218843014400012. eprint: <https://doi.org/10.1142/S0218843014400012>.
- [3] Michael Fenton i in. „PonyGE2”. W: *Proceedings of the Genetic and Evolutionary Computation Conference Companion* (2017). DOI: 10.1145/3067695.3082469.
- [4] Michael zur Muehlen i Jan Recker. „How Much Language Is Enough? Theoretical and Practical Use of the Business Process Modeling Notation”. W: *Advanced Information Systems Engineering*. Red. Zohra Bellahsene i Michel Léonard. Berlin, Heidelberg: Springer Berlin Heidelberg, 2008, s. 465–479. ISBN: 978-3-540-69534-9.
- [5] Saul B. Needleman i Christian D. Wunsch. „A general method applicable to the search for similarities in the amino acid sequence of two proteins”. English (US). W: *Journal of Molecular Biology* 48.3 (mar. 1970), s. 443–453. ISSN: 0022-2836. DOI: 10.1016/0022-2836(70)90057-4.